
Proyecto Final: Predicción del éxito académico en educación superior

Angela Porres Cobb
2ºB IMAT

1 Exploración inicial y análisis descriptivo del conjunto de datos

El conjunto de datos analizado en este proyecto recoge información detallada sobre estudiantes de educación superior, incluyendo variables de carácter demográfico, académico, socioeconómico y de rendimiento. El análisis exploratorio previo tiene como objetivo comprender la estructura de los datos, identificar patrones y detectar relaciones útiles para la modelización.

En primer lugar, se observa que el dataset presenta una estructura heterogénea, combinando variables numéricas (edad, calificaciones, número de asignaturas) y categóricas (género, nacionalidad, vía de acceso o situación administrativa).

Las variables demográficas permiten describir el perfil del estudiante, mientras que las relacionadas con el acceso a la universidad, como la nota de admisión, aportan información sobre su nivel académico previo. El número de asignaturas aprobadas, evaluadas y la calificación media constituyen indicadores claros del desempeño inicial del estudiante. En general, un buen rendimiento en esta etapa temprana suele estar asociado con una mayor probabilidad de graduarse, mientras que un bajo rendimiento puede anticipar situaciones de abandono.

A nivel global, el análisis exploratorio permite identificar varias relaciones relevantes. En primer lugar, existe una asociación clara entre el rendimiento académico temprano y la trayectoria final del estudiante. En segundo lugar, los factores socioeconómicos parecen influir en el riesgo de abandono, lo que sugiere que el éxito académico no depende únicamente de la capacidad individual, sino también del contexto del estudiante.

2 Preprocesado realizado y decisiones metodológicas adoptadas

Una vez realizado el análisis exploratorio del conjunto de datos, es necesario que se lleve a cabo una fase de preprocesamiento de los datos para su posterior uso en modelos de aprendizaje automático.

En primer lugar, se realizó una revisión general de la calidad de los datos. Para tratar los valores faltantes, en las variables numéricas se utilizó la mediana, ya que es más robusta frente a valores extremos, mientras que en las variables categóricas se imputó la categoría más frecuente. Además, dado que algunas variables (como las calificaciones o el número de asignaturas) pueden estar en diferentes rangos, se estandarizaron para que tuvieran media 0 y desviación típica 1, y las variables categóricas se transformaron mediante one-hot encoding, convirtiéndolas en variables numéricas adecuadas para los modelos.

Por otro lado, se llevó a cabo una partición del dataset en conjuntos de entrenamiento y test, con el fin de evaluar el rendimiento de los modelos de forma objetiva. Esta separación permite estimar la capacidad de generalización de los modelos sobre datos no vistos. Para complementar este proceso se aplica validación cruzada para obtener estimaciones más robustas del rendimiento.

En conjunto, las decisiones metodológicas adoptadas en esta fase tiene como objetivo intentar garantizar que los modelos construidos posteriormente sean robustos, interpretables y metodológicamente correctos.

3 Tarea 1. Clasificación supervisada

El objetivo de esta tarea es construir un modelo de clasificación supervisada multiclase capaz de predecir la situación final del estudiante, que puede ser *abandono*, *matriculado* o *graduado*. Se trata de un problema con cierto desbalance entre clases, donde la categoría *matriculado* es la menos representada, lo que condiciona tanto la elección de métricas como las decisiones de modelado.

3.1 Métricas de evaluación

Dado el desbalance entre clases, las métricas principales durante la validación cruzada son el F1-macro y la *balanced accuracy*. El F1-macro asigna el mismo peso a cada clase independientemente de su frecuencia, evitando que las clases mayoritarias dominen la evaluación. La *balanced accuracy* calcula el *recall* medio por clase, siendo igualmente robusta frente al desbalance. Ambas métricas permiten evaluar el rendimiento del modelo de forma equilibrada entre todas las clases.

En el conjunto de test se complementa el análisis con *accuracy*, F1-weighted, el *classification report* completo y la matriz de confusión, que permiten obtener una visión más global del rendimiento y analizar en detalle el comportamiento del modelo en cada clase.

3.2 Modelos evaluados y selección

Se comparan tres modelos mediante validación cruzada: un *DummyClassifier* como base, una *LogisticRegression* como modelo lineal y un *RandomForestClassifier* como modelo no lineal.

Modelo	F1-macro	Std	Balanced Acc.	Std
LogisticRegression	0.7170	0.0078	0.7264	0.0061
RandomForest	0.7132	0.0150	0.7056	0.0149
Dummy	0.2220	0.0002	0.3333	0.0000

Table 1: Resultados de validación cruzada.

La regresión logística obtiene el mejor F1-macro medio (0.717) y la mayor *balanced accuracy* (0.726), superando al *RandomForestClassifier* en ambas métricas. Además, presenta menor variabilidad entre pliegues: la desviación estándar del F1-macro es de 0.008, aproximadamente la mitad que la del Random Forest (0.015), lo que indica que el modelo lineal es más estable. Por este motivo, se selecciona como modelo final.

El hecho de que un modelo lineal supere a uno más complejo sugiere que el problema no es especialmente difícil en términos de separabilidad de clases. Variables como el número de asignaturas aprobadas o las notas medias tienen una relación bastante directa con la situación final del estudiante, lo que permite a la regresión logística capturar gran parte de la señal predictiva sin necesidad de modelar relaciones no lineales.

3.3 Resultados en test

En el conjunto de test, el modelo alcanza una *accuracy* de 0.741, una *balanced accuracy* de 0.700 y un F1-macro de 0.694, valores coherentes con los obtenidos en validación cruzada. Esto indica que el modelo es estable y generaliza correctamente.

El comportamiento por clases es desigual. La clase *graduado* obtiene los mejores resultados (precisión 0.86, recall 0.82, F1-score 0.84), lo que indica que el modelo identifica bien a estos estudiantes. La clase *abandono* presenta un rendimiento intermedio (F1-score 0.76). Por el contrario, la clase *matriculado* es claramente la más difícil de predecir (F1-score 0.48).

Como se observa en la Figura 1, muchos estudiantes matriculados se clasifican erróneamente como graduados o abandonos. Esto sugiere que esta clase comparte características con ambas y que su separación no es clara con las variables disponibles.

3.4 Análisis del desbalance y ponderación de clases

La distribución de clases es: 49.9% graduados, 32.1% abandonos y 17.9% matriculados. Este desbalance se refleja directamente en los resultados, siendo la clase matriculado la peor predicha.




Figure 1: Comparacion de las matrices de confusión de ambos modelos

Para intentar mejorar su rendimiento, se probó asignar mayor peso a esta clase durante el entrenamiento. Esto llevó a seleccionar un *RandomForestClassifier*, pero con mayor variabilidad (0.016 frente a 0.006 en regresión logística).

En test, los resultados apenas cambian (F1-macro de 0.690), y la mejora en la clase matriculado es mínima, tal y como se observa en la Figura 1. Esto indica que el problema no es solo el desbalance, sino la dificultad de separar esta clase, ya que sus características son similares a las de las otras dos.

3.5 Importancia de variables

El análisis de *permutation importance* muestra que las variables más relevantes son *asignaturas_2sem_aprobadas* y *asignaturas_1sem_aprobadas*. Esto confirma que el número de asignaturas aprobadas es el principal factor para predecir la situación final del estudiante.

En cambio, las variables socioeconómicas tienen una importancia mucho menor, lo que refuerza la idea de que el rendimiento durante el curso es más determinante que el perfil de entrada.

Sin embargo, varias de las variables más importantes pertenecen al segundo semestre. Esto implica que el modelo está utilizando información que no estaría disponible en un escenario de predicción temprana, lo que puede inflar artificialmente su rendimiento.

3.6 Conclusiones

El modelo predice correctamente la mayoría de los casos, especialmente en las clases graduado y abandono. Sin embargo, la clase matriculado sigue siendo la más difícil de identificar, debido al solapamiento con las otras dos.

El rendimiento académico durante el curso es, con diferencia, el factor más importante, mientras que el perfil socioeconómico tiene un papel secundario. No obstante, la dependencia de variables del segundo semestre limita la utilidad del modelo para predicción temprana, lo que motiva el análisis realizado en la Tarea 2.

4 Tarea 2. Regresión supervisada

El objetivo de esta tarea es construir un modelo de regresión supervisada que sea capaz de predecir la calificación media obtenida por un estudiante en el segundo semestre (*nota_media_2sem*). Además, se buscará responder a la pregunta: ¿es posible anticipar el rendimiento del segundo semestre usando únicamente información previa al mismo?

El principal riesgo metodológico en este problema es la fuga de información o *data leakage*, que ocurre cuando se incluyen como variables predictoras datos que son contemporáneos al *target* o que lo revelan de forma directa o indirecta. Si un modelo tiene acceso durante el entrenamiento a variables que en la práctica no estarían disponibles en el momento de hacer la predicción, las métricas de validación resultarán artificialmente infladas y el modelo será inútil en un escenario real.

4.1 Comparativa de selecciones de variables

Para estudiar en profundidad qué información aporta realmente poder predictivo, se comparan tres configuraciones de variables:

Configuración A: Con todas las variables. Se incluyen todas las columnas del dataset salvo el *target*, resultando en 35 variables predictoras. Esta configuración no es metodológicamente válida, pero sirve para determinar en qué medida las variables del segundo semestre afectan el aprendizaje del modelo.

Configuración B: Sin variables del segundo semestre. Se eliminan todas las variables del segundo semestre, quedando 30 variables. El modelo dispone de características personales, socioeconómicas y toda la información académica del primer semestre.

Configuración C: Solo variables de perfil, sin información académica del curso. Se excluyen todas las variables relacionadas con cualquier semestre, dejando 24 variables únicamente referidas a características de entrada del estudiante.

4.2 Modelos evaluados

Se comparan cuatro modelos con distintos niveles de complejidad. El *DummyRegressor* se utiliza como referencia básica, ya que siempre predice la media. *LinearRegression* es un modelo sencillo e interpretable. Por último, *RandomForestRegressor* y *GradientBoostingRegressor* son modelos más avanzados que permiten capturar relaciones más complejas entre las variables.

4.3 Resultados y análisis




Figure 2: Evaluación del modelo RandomForestRegressor en el conjunto de test

Configuración A. El *GradientBoostingRegressor* obtiene el mejor rendimiento en validación cruzada con un RMSE medio de 0.83 y un R^2 de 0.974, seguido muy de cerca por el *RandomForestRegressor*. En test, alcanza un R^2 de 0.971. Estas cifras son muy altas y son una clara señal de *leakage*, ya que el modelo tiene acceso a variables del segundo semestre que están directamente relacionadas con el *target*. La regresión lineal obtiene un R^2 de 0.81 en validación, lo que indica que, aunque gran parte de la relación es lineal, existen componentes no lineales que los modelos más complejos capturan mejor.

Configuración B. Al eliminar el *leakage*, el rendimiento cae de forma notable. El *RandomForestRegressor* obtiene un R^2 de 0.73 en test. Esto indica que, usando únicamente información del primer semestre y del perfil del estudiante, se puede explicar aproximadamente el 73% de la variabilidad de la nota del segundo semestre, tal y como se observa en la Figura 2.

La desviación estándar del R^2 en validación cruzada es de 0.033, lo que indica que el rendimiento es bastante estable. Los modelos más complejos mantienen esa estabilidad, pero la regresión lineal también obtiene un R^2 similar (≈ 0.73) y una variabilidad parecida, por lo que en este caso resulta casi igual de competitiva. Esto sugiere que, una vez eliminado el *leakage*, la relación entre las variables del primer semestre y el *target* es en gran parte lineal.

Configuración C. Esta configuración produce los resultados más bajos. El mejor modelo alcanza un R^2 de 0.27 en test, lo que indica que las variables demográficas y socioeconómicas explican una

parte limitada del rendimiento académico. Esto sugiere que el perfil del estudiante tiene influencia, pero no es suficiente para predecir con precisión su rendimiento.

4.4 Factores asociados al rendimiento académico y conclusiones

La diferencia entre la configuración B ($R^2 = 0.73$) y la C ($R^2 = 0.27$) muestra que la información académica del primer semestre concentra la mayor parte de la capacidad predictiva: conocer el rendimiento del estudiante en este periodo casi triplica la varianza explicada respecto a utilizar únicamente su perfil de entrada.

El perfil socioeconómico también tiene un efecto real, pero claramente secundario. Su correlación con el rendimiento no implica causalidad, ya que pueden existir variables no observadas, como la motivación, que estén influyendo en ambos.

En conjunto, los resultados sugieren que la trayectoria académica presenta una fuerte continuidad: el primer semestre no es solo un periodo inicial, sino un indicador muy informativo de lo que ocurrirá después. Por el contrario, las condiciones estructurales del estudiante influyen, pero no determinan su resultado final. Finalmente, excluir las variables del segundo semestre es imprescindible para construir un modelo metodológicamente válido, siendo la configuración B el escenario más realista y útil de los tres analizados.

5 Tarea 3: Aprendizaje no supervisado

El objetivo de esta tarea es aplicar técnicas de aprendizaje no supervisado para descubrir estructuras en los datos, identificar perfiles de estudiantes con características diferenciadas y extraer información útil para interpretar el fenómeno del abandono y el éxito académico. A diferencia de las tareas anteriores, aquí no hay una variable objetivo. El objetivo es encontrar grupos directamente en los datos, sin definir categorías previamente, utilizando todas las variables del dataset excepto *objetivo*, que se reserva para su interpretación a posteriori. Se emplean así 36 variables, de las cuales 19 son numéricas y 17 categóricas. A diferencia de la tarea de regresión, en este contexto no es necesario excluir las variables del segundo semestre.

5.1 Elección del número de clusters

Para seleccionar el número óptimo de clusters se emplea el coeficiente de silueta medio, calculado para valores de k entre 2 y 6. Este coeficiente mide qué tan similar es cada punto a su propio cluster en comparación con el más cercano: valores próximos a 1 indican buena separación, valores cercanos a 0 indican solapamiento y valores negativos indican asignaciones incorrectas.

k	Silhouette score
2	0.2087
3	0.2295
4	0.1543
5	0.0905
6	0.0835

Table 2: Coeficiente de silueta medio para distintos valores de k .

Como se puede ver en la Tabla 2, el valor máximo se obtiene con $k = 3$, que es el seleccionado. Este resultado indica que los clústeres presentan cierto solapamiento y no están perfectamente separados. Para evaluar la estabilidad de los clústeres, se repite el ajuste de KMeans con distintas semillas. La desviación estándar del coeficiente de silueta es prácticamente nula (0.0002), lo que indica que los clusters son estables y no dependen de la inicialización aleatoria.

5.2 Visualización mediante PCA

Para visualizar los clústeres en dos dimensiones se aplica PCA, como se observa en la Figura 3, proyectando los datos sobre los dos primeros componentes principales. En la figura se distinguen tres grupos, aunque con cierto solapamiento, especialmente entre los clústeres más cercanos al origen.




Figure 3: Proyección en 2D mediante PCA de los clusters obtenidos con K-Means ($k = 3$)

Uno de los clústeres aparece más claramente separado a lo largo del eje del primer componente principal, mientras que los otros dos presentan mayor proximidad y dispersión.

El primer componente explica el 23.4% de la varianza y el segundo el 9.7%, acumulando un 33.1%. Esto implica que la representación en 2D solo recoge una parte limitada de la información original. Como consecuencia, al proyectar los datos desde un espacio de mayor dimensión a dos dimensiones, se pierde información relevante, lo que hace que los clústeres aparezcan más solapados de lo que realmente están.

5.3 Análisis e interpretación de los clusters

El modelo con $k = 3$ produce la siguiente distribución representada en la Tabla 3:

Cluster	Tamaño	% del total
0	273	6.2 %
1	3297	74.5 %
2	854	19.3 %

Table 3: Distribución de estudiantes por cluster

Cluster	Abandono	Graduado	Matriculado
0	23.8 %	63.0 %	13.2 %
1	19.8 %	59.5 %	20.7 %
2	82.2 %	8.9 %	8.9 %

Table 4: Distribución de la variable objetivo por cluster

La distribución de los clústeres es notablemente desequilibrada, con un grupo mayoritario que agrupa a la mayor parte de los estudiantes y dos grupos minoritarios con características diferenciadas. Este desequilibrio sugiere que la mayor parte de los estudiantes comparte un perfil "típico" y que los grupos minoritarios representan desviaciones significativas respecto a ese perfil central.

Cluster	Nota 1sem	Nota 2sem	Adm.	Aprobadas	Edad
0	12.66	12.67	129.47	11.70	28.70
1	12.74	12.52	126.81	5.26	22.10
2	1.91	0.59	126.83	0.35	26.03

Table 5: Perfil medio de variables numéricas por cluster.

5.4 Perfiles de estudiantes

Cluster 2 — Riesgo de abandono. Este grupo, que representa el 19.3% del total, presenta una nota media del primer semestre de 1.91 y del segundo semestre de 0.59, con solo 0.35 asignaturas aprobadas de media en el primer semestre. Como consecuencia, se observa una tasa de abandono muy elevada, del 82.2%. Además, el 29.5% de estos estudiantes tiene la matrícula fuera de plazo o con incidencias, y la tasa de becas es también de las más bajas (10.1%). En conjunto, se trata de un perfil de estudiante con un rendimiento académico prácticamente nulo, que en la mayoría de los casos acaba abandonando los estudios.

Cluster 1 — Perfil mayoritario. Este grupo agrupa al 74.5% de los estudiantes y representa el perfil típico. La nota media del primer semestre es de 12.74, con 5.26 asignaturas aprobadas, y la tasa de graduación es del 59.5%. La edad media de matriculación es la más baja (22.1 años), lo que

Cluster	Matrícula al día (sí)	Becado (sí)
0	90.5 %	11.7 %
1	92.4 %	29.8 %
2	70.5 %	10.1 %

Table 6: Distribución de variables categóricas por cluster.

sugiere que este cluster concentra a estudiantes que acceden directamente desde el bachillerato o ciclos formativos en la franja de edad habitual. La tasa de becas es la más alta de los tres grupos (29.8%), lo que podría indicar que los estudiantes más jóvenes con dedicación acceden en mayor medida a ayudas al estudio.

Cluster 0 — Estudiantes mayores con buen rendimiento. Este grupo minoritario (6.2% del total) presenta el mejor perfil académico: una nota media del primer semestre de 12.66 y 11.70 asignaturas aprobadas de media, lo que indica que estos estudiantes cursan y superan un número significativamente mayor de materias que el grupo mayoritario. La nota de admisión también es ligeramente superior (129.47 frente a 126.81 del cluster 1). La característica más diferenciadora es la edad: estos estudiantes se matriculan de media a los 28.7 años, frente a los 22.1 del cluster 1, lo que sugiere un perfil de estudiante adulto, posiblemente con experiencia laboral previa. La tasa de graduación (63%) es la más alta, mientras que la tasa de abandono (23.8%) es ligeramente superior a la del cluster 1, pero muy inferior a la del cluster 2. La tasa de becas es baja (11.7%), coherente con perfiles de mayor edad que suelen tener menos acceso a ayudas dirigidas a estudiantes a tiempo completo.

A partir del análisis surgen dos cuestiones clave: si es posible identificar perfiles de estudiantes diferenciados y si existen variables sobre las que una institución educativa podría intervenir para mejorar los resultados.

En cuanto a la primera, se pueden distinguir distintos perfiles de estudiantes, aunque con cierto solapamiento entre ellos. El cluster 2 representa un perfil claramente diferenciado, con valores académicos muy bajos y tasas de aprobación cercanas a cero. La separación entre los clústeres 0 y 1, en cambio, es más gradual y está definida principalmente por la edad de matriculación y el número de asignaturas cursadas, más que por diferencias significativas en rendimiento.

En cuanto a la segunda cuestión, hay que tener cuidado, ya que una asociación entre variables no implica una relación causal. Los resultados permiten identificar factores vinculados al riesgo de abandono, pero no garantizan que intervenir sobre ellos mejore directamente el rendimiento. No obstante, algunos indicadores pueden ser relevantes. La situación de la matrícula destaca como señal de alerta temprana: el 29.5% de los estudiantes del cluster con mayor abandono presenta incidencias en la matrícula, frente al 7.6%–9.5% en los otros grupos. Aunque esta variable puede ser consecuencia y no causa, su identificación temprana podría utilizarse para activar medidas de apoyo y orientación.

El perfil del cluster 2 sugiere que el abandono no siempre es un proceso gradual, sino que, en muchos casos, es detectable desde las primeras semanas. Un estudiante que no aprueba prácticamente ninguna asignatura en el primer semestre tiene una probabilidad del 82% de abandonar. Esto apoya el uso de sistemas de alerta temprana basados en el seguimiento del rendimiento durante el primer semestre, que además pueden complementarse con el modelo de regresión de la Tarea 2 desde un enfoque predictivo.

6 Interpretación crítica de los resultados

Los resultados de las tres tareas muestran un patrón claro: el rendimiento académico durante el curso es la variable que mejor explica la evolución del estudiante. Aun así, es importante interpretar estos resultados con cierta cautela y entender bien qué implican.

Por un lado, el buen rendimiento de los modelos no significa necesariamente que el problema sea sencillo, sino que existen variables muy informativas, especialmente las relacionadas con las asignaturas aprobadas, que resumen bien la situación académica del estudiante. Esto explica que incluso modelos relativamente simples obtengan buenos resultados.

Por otro lado, la dificultad para predecir la clase *matriculado* en la clasificación y el solapamiento observado en el clustering indican que no todos los perfiles están claramente definidos. En particular, los estudiantes en situaciones intermedias no siguen patrones tan marcados, lo que limita la capacidad de los modelos para diferenciarlos con precisión.

Además, el análisis pone de manifiesto un aspecto importante: parte del rendimiento de los modelos depende de variables muy cercanas al resultado final. Esto es especialmente evidente en el uso de datos del segundo semestre, que pueden introducir *leakage* y dar una visión demasiado optimista del rendimiento real del modelo.

Por último, conviene recordar que los modelos identifican patrones estadísticos, pero no explican las causas. Factores no observados, como la motivación del estudiante o su contexto personal, pueden influir en los resultados sin aparecer en los datos, lo que limita la interpretación de los modelos.

7 Conclusiones finales y limitaciones del estudio

El principal resultado del estudio es que el rendimiento académico en las primeras fases del curso permite anticipar con bastante fiabilidad la trayectoria futura del estudiante. Esto abre la puerta a aplicaciones prácticas, especialmente en el diseño de sistemas de seguimiento y apoyo desde el inicio del curso.

En este sentido, los resultados sugieren que las instituciones educativas podrían centrarse en identificar rápidamente a los estudiantes con bajo rendimiento inicial, ya que constituyen el grupo con mayor riesgo de abandono. Actuar sobre este grupo puede tener un impacto directo en la reducción del abandono.

Además, el análisis muestra que, aunque el contexto socioeconómico influye, no es el factor más determinante. Esto sugiere que existe margen de intervención durante el curso para mejorar el rendimiento de los estudiantes.

No obstante, el estudio presenta varias limitaciones. Por un lado, los resultados dependen de este dataset y pueden no generalizarse a otros contextos educativos. Por otro, faltan variables relevantes, como factores personales o motivacionales, que podrían influir en el rendimiento. Por último, los modelos identifican relaciones estadísticas, por lo que no permiten establecer qué intervenciones concretas mejorarían los resultados.

En conjunto, el trabajo muestra que es posible anticipar el riesgo académico a partir de información temprana, pero también que cualquier aplicación práctica debe realizarse con cautela y teniendo en cuenta estas limitaciones.